

SEMINARIUM BADAWCZE

Automating Aggregation Strategy Selection in Federated Learning


Niniejsza prezentacja została wykonana na podstawie artykułu
„**Automating Aggregation Strategy Selection in Federated Learning**”
autorstwa Dian S. Y. Pang, Endrias Y. Ergetu, Eric Topham, Ahmed E. Fetit
Imperial College London / OctaiPipe
przez Michała Kubinę i Dominikę Zakrzewską.

Przegląd literatury: Wprowadzenie do FL

Istota Uczenia Federacyjnego (FL)

Uczenie federacyjne zrewolucjonizowało podejście do trenowania modeli uczenia maszynowego poprzez porzucenie tradycyjnego paradygmatu centralizacji danych.

Zamiast przysyłać poufne dane lokalne na serwer centralny, klienci (np. urządzenia mobilne, serwery szpitalne) trenują modele lokalnie i wymieniają jedynie parametry (wagi lub gradienty).



Krok 1: Inicjalizacja → Krok 2: Trening lokalny →
Krok 3: Agregacja globalna

Główna korzyść: Prywatność

Dane surowe nigdy nie opuszczają lokalnych urządzeń brzegowych, co jest kluczowe w medycynie i finansach.

Przegląd literatury: Klasyczny FedAvg

Algorytm McMahan et al. (2017)

U podstaw uczenia federacyjnego leży algorytm **Federated Averaging (FedAvg)**. Agreguje on lokalne wagi modeli za pomocą średniej ważonej wielkością lokalnych zbiorów danych.

$$w_{t+1} = \sum_{k=1}^K \frac{n_k}{n} w_{t+1}^k$$

Gdzie n_k to liczba próbek klienta, a n to całkowita liczba próbek we wszystkich węzłach.

Ograniczenia FedAvg

- Zakłada, że dane klientów są niezależne i tożsamo rozłożone (IID).
- W warunkach silnej heterogeniczności (non-IID) wykazuje wolną zbieżność.
- Wymaga ciągłej, kosztownej komunikacji sieciowej.
- Podatny na destabilizację przez klientów z zaburzonymi rozkładami.

Przegląd literatury: Problem Non-IID

Heterogeniczność statystyczna danych

W rzeczywistych wdrożeniach urządzenia klienckie generują dane w skrajnie różnych środowiskach (np. różne nawyki użytkowników, specyfika sensorów brzegowych).

Prowadzi to do zjawiska **non-IID**, czyli naruszenia założenia o tożsamości i niezależności rozkładów prawdopodobieństwa danych lokalnych.

Statistical Heterogeneity obejmuje: Non-IID Data, Information Quality & Quantity, Fairness Issues, Massively Distributed Data, Inconsistent/fake/not-valid data.

Konsekwencja badawcza

Lokalne aktualizacje gradientów stają się obciążonymi estymatorami globalnego gradientu optymalizacyjnego, drastycznie spowalniając zbieżność sieci.

Przegląd literatury: Zjawisko Client Drift

Przeuczenie do minimów lokalnych

Podczas uczenia lokalnego klienci optymalizują model względem własnych funkcji kosztu $F_k(w)$.

Przy danych non-IID minima lokalne poszczególnych klientów są od siebie znacznie oddalone. Model optymalizowany u klienta oddala się od globalnego optimum (**dryf klienta**).

Uśrednienie tak rozbieżnych modeli w FedAvg drastycznie obniża ostateczną dokładność.

Mechanizm dryfu

Krok 1: Klient wykonuje wiele epok lokalnych, dopasowując się silnie do lokalnego zaburzonego zbioru.

Krok 2: Lokalne gradienty wskazują przeciwne kierunki.

Krok 3: Średnia z tych wektorów nie odzwierciedla prawdziwego optimum globalnego.

Przegląd literatury: Empiryczny wpływ heterogeniczności (Zhao et al.)

Ilościowy dowód degradacji FedAvg

Zhao et al. (2018) empirycznie wykazali negatywny wpływ heterogeniczności danych na FedAvg, demonstrując wyraźny spadek dokładności w warunkach non-IID.

Rozmiar tej różnicy w wydajności powiększa się w miarę wzrostu stopnia heterogeniczności danych klientów.

Wniosek komunikacyjny

Analizy teoretyczne ugruntowały fakt, że heterogeniczność danych zwiększa liczbę rund komunikacyjnych potrzebnych do osiągnięcia założonej dokładności, dodatkowo pogłębiając wąskie gardło komunikacyjne w FL.

Przegląd literatury: Mapowania empiryczne (Li et al.)

Odwzorowania heterogeniczność–strategia

Li et al. symulują zróżnicowane warunki non-IID i oceniają strategie agregacji w tych warunkach, tworząc empiryczne mapowania między poziomem heterogeniczności a wydajnością strategii.

Podobne podejście empiryczne zaprezentował Dubey (2025), który skwantyfikował heterogeniczność jako metrykę i rekomendował strategię sprawdzone w porównywalnych warunkach.

Kluczowe ograniczenie

Większość tych prac zwraca **tylko nazwy strategii**, bez strojenia ich parametrów (np. μ w FedProx czy f w Krum), mimo że parametry te mają istotny wpływ na wydajność.

Sztuczne tabele mapowań nie adaptują się do nowych algorytmów agregacji i mogą nie generalizować się na zbiory danych o odmiennej charakterystyce.

Przegląd literatury: Agregacja odporna

Zagrożenia ze strony złośliwych węzłów

W rozproszonych środowiskach FL niektórzy klienci mogą celowo zatruwać dane (**label poisoning**) lub wysyłać zniekształcone gradienty w celu przejścia/zniszczenia modelu globalnego.

Klasyczny algorytm FedAvg jest skrajnie podatny nawet na jednego złośliwego klienta o dużym wolumenie danych.

Rozwiązania z zakresu Robust Aggregation

- **FedMedian:** Oblicza medianę współrzędna po współrzędnej zamiast średniej, odrzucając wartości skrajne.
- **FedTrimmedAvg:** Odrzuca określony procent skrajnych aktualizacji z obu końców spektrum przed uśrednieniem.
- **Krum / Multi-Krum:** Wybiera jedną aktualizację najbardziej spójną z otoczeniem euklidesowym.

Przegląd literatury: Taksonomia skośności

01

Label Skew

Występuje, gdy rozkłady etykiet klas różnią się znacząco między urządzeniami. Na przykład jeden telefon ma zdjęcia wyłącznie psów, a inny wyłącznie samochodów.

02

Feature Skew

Klienci posiadają te same etykiety, ale ich cechy wejściowe mają inne rozkłady (np. zdjęcia wykonywane przy różnym oświetleniu lub przez kamery o różnej rozdzielczości).

03

Quantity Skew

Dysproporcja w ilości posiadanych danych. Jeden z klientów posiada 10 000 próbek treningowych, podczas gdy pozostali zaledwie po 10–15 próbek.

Przegląd literatury: Concept Drift

Dynamika zmian środowiskowych

Zjawisko **Concept Drift** (przesunięcie pojęcia) zachodzi wówczas, gdy powiązanie probabilistyczne między cechami a etykietami $P(Y | X)$ zmienia się w czasie lub przestrzeni.

W uczeniu federacyjnym zjawisko to przejawia się tym, że to samo zachowanie sensora może oznaczać różne stany maszyny w zależności od lokalizacji fizycznej urządzenia.

Implikacje dla agregacji

Modele agregowane statycznie nie nadążają za dynamicznym concept driftem. Wymaga to ciągłej adaptacji wag i elastycznych algorytmów, które potrafią korygować historię uczenia.

Złożone interakcje dynamiczne czynią manualną ocenę administratora FL bezużyteczną.

Przegląd literatury: Metoda Fed-Hetero

Samoewaluacja rozbieżności wag

Wprowadzona przez Kummaya et al. (2025), metoda **Fed-Hetero** kładzie nacisk na wykrywanie skośności w locie poprzez analizę wag modeli.

Mierzy ona tzw. **dywergencję wagową** pomiędzy aktualizacjami klientów a modelem globalnym jako wczesny indykator zaburzeń.

Trzy filary Fed-Hetero

1. **Wykrywanie ilościowe:** Bezpośrednia ocena różnic w rozmiarach lokalnych zbiorów danych.
2. **Podobieństwo wizualne:** Ocena skośności cech obrazu na bazie metryk podobieństwa strukturalnego.
3. **Dywergencja Jensena-Shannona:** Obliczana bezpośrednio na histogramach rozkładu klas etykiet u klientów.

Przegląd literatury: Dubey (2025)

Wielomodalne metryki rozbieżności

Dubey (2025) zaproponował zaawansowane podejście do szacowania rozbieżności danych w trzech wymiarach jednocześnie:

- **Skośność etykiet:** Wykorzystanie metryki JSD na histogramach klas.
- **Przesunięcie cech:** Zastosowanie odległości Wassersteina na reprezentacjach wejściowych (embeddings).
- **Przesunięcie wyjść modelu:** Badanie entropii i rozbieżności rozkładów softmax sieci.

Rola wyjść softmax

Dzięki analizie rozkładów prawdopodobieństwa predykcji, metoda Dubey pozwala na wykrywanie zniekształceń pewności modelu, co wykracza poza zwykłe analizowanie danych wejściowych.

Przegląd literatury: Mawela (2025)

Automatyzacja FL z użyciem LLM

Praca Mawela et al. (2025) zaprezentowała rozwiązanie webowe integrujące duże modele językowe (LLM) do automatyzacji konfiguracji eksperymentów FL.

LLM pomaga użytkownikowi zdefiniować poprawne pliki konfiguracyjne i zakresy hiperparametrów w oparciu o naturalnojęzykowy opis środowiska.

Zasadnicze ograniczenia

1. System zakładał sztywne wykorzystanie algorytmu FedAvg – nie optymalizował samej strategii agregacji.
2. Brak automatycznej detekcji heterogeniczności – system opierał się wyłącznie na deklaracjach wpisywanych przez człowieka.
3. Całkowity brak optymalizacji parametrów wewnętrznych strategii odpornych.

Przegląd literatury: Shen et al. (2023)

Edge AI i autonomiczne systemy agentowe

Praca Shen et al. (2023) badała użycie LLM do sterowania autonomicznymi agentami sztucznej inteligencji na brzegu sieci (Edge AI).

LLM były odpowiedzialne za dynamiczne przydzielanie zadań obliczeniowych i monitorowanie kondycji urządzeń brzegowych.

Luka w badaniach optymalizacyjnych

Podobnie jak u Maweli, badania te skupiały się na orkiestracji infrastruktury i „scaffoldingu” eksperymentów, pomijając matematyczne aspekty optymalizacji procesów agregacji i przeciwdziałania zniekształceniom statystycznym danych.

Luki badawcze w literaturze naukowej

Brak optymalizacji parametrów

Większość prac empirycznych rekomenduje jedynie nazwy strategii (np. „użyj FedProx”), całkowicie pomijając strojenie ich parametrów wewnętrznych (takich jak współczynnik μ czy dopuszczalny próg błędu w Krum), które krytycznie wpływają na wyniki.

Wysoki koszt tradycyjnego HPO

Metody typu AutoML bazujące na przeszukiwaniu siatkowym lub optymalizacji bayesowskiej wymagają setek pełnych cykli treningu FL, co przy ograniczeniach energetycznych i sieciowych urządzeń brzegowych jest całkowicie nierealne.

Brak połączenia detekcji–wybór

Istniejące biblioteki albo potrafią badać skośność danych (EDA), albo potrafią agregować aktualizacje. Brakuje jednolitego, bezszumowego i w pełni autonomicznego pomostu łączącego diagnostykę z bezpośrednią rekonfiguracją potoku.

Przegląd literatury: Tabela porównawcza

Praca naukowa	Detekcja het.	Wybór strategii	Strojenie pa-ram.	Automatyzacja LLM	Świadomość budżetu
Li et al. (2021)	Nie	Tak (Sztywne reguły)	Nie	Nie	Nie
Dubey (2025)	Tak	Tak (Sztywne reguły)	Nie	Nie	Nie
Fed-Hetero (2025)	Tak (Lekka)	Nie	Nie	Nie	Nie
Mawela et al. (2025)	Nie	Nie	Nie	Tak	Nie
Shen et al. (2023)	Nie	Nie	Nie	Tak	Nie
Zaproponowane rozw.	Tak (Rozproszone PCA/JSD)	Tak (Adaptacyjny wybór)	Tak (Optymalizacja GA)	Tak (One-Shot reasoning)	Tak (1-tryb / 8-trybów)

Cel i motywacja autorów artykułu

Bariera wejścia w Federated Learning

Skuteczne wdrożenie systemów uczenia federacyjnego wymaga unikalnego połączenia wiedzy z zakresu optymalizacji matematycznej, teorii systemów rozproszonych oraz uczenia maszynowego.

Z powodu braku bezpośredniego wglądu w dane klientów (ze względów prywatnościowych), dobór odpowiedniej strategii agregacji przypomina błądzenie po omacku.

Główne cele badawcze

- **Automatyzacja pełnego cyklu:** Od diagnostyki danych po egzekucję w Flower.
- **Świadomość zasobów:** Dostosowanie procesu optymalizacji do skrajnie różnych możliwości obliczeniowych urządzeń brzegowych.
- **Minimalizacja interwencji ludzkiej:** Usunięcie inżyniera z pętli decyzyjnej.

Dwa tryby działania systemu

1. Tryb Single-Trial (Jednorazowy)

Dedykowany dla urządzeń o skrajnie ograniczonych zasobach obliczeniowych i sieciowych.

System przeprowadza szybką i taną analizę diagnostyczną (EDA), a następnie za pomocą zaawansowanego wnioskowania LLM (GPT-4.1) generuje optymalną konfigurację w zaledwie jednym podejściu.

2. Tryb Multi-Trial (Wielokrotny)

Dedykowany dla środowisk z elastycznym budżetem obliczeniowym.

Wykorzystuje lekki, wysoce zoptymalizowany algorytm genetyczny (GA) ograniczony sztywno do maksymalnie 8 prób treningowych, co pozwala na precyzyjne dostosowanie hiperparametrów wewnątrz obiecujących klas strategii.

Architektura potoku decyzyjnego



Rozproszona analiza EDA

Klienci bezpiecznie obliczają lokalne statystyki bez przesyłania danych surowych.

Agregacja na serwerze

Serwer łączy metryki, wyliczając globalne wskaźniki skośności i anomalii.

Generowanie promptu

Formatowanie wyników diagnostyki do strukturalnego szablonu XML/JSON.

Wnioskowanie i start FL
Weryfikacja składniowa konfiguracji i uruchomienie uczenia we Flower.

Moduł wykrywania heterogeniczności

Trójtorowy system diagnostyczny

Aby dostarczyć modelowi językowemu precyzyjnych i pozbawionych szumu informacji, autorzy opracowali unikalny moduł diagnostyczny działający w trzech obszarach:

- **Label Skew Detection Module:** Wykrywa zaburzenia rozkładu klas etykiet wyjściowych.
- **Outlier Detection Module:** Identyfikuje potencjalnie złośliwe lub uszkodzone węzły klienckie.
- **Feature Skew Detection Module:** Wykrywa przesunięcia rozkładów cech wejściowych (kowariancji).

Zasady prywatności (Privacy-Preserving)

Żadne surowe próbki danych (np. piksele obrazów, wpisy w bazie danych) nie są przesyłane do serwera podczas analizy. Moduły operują wyłącznie na rozproszonych reprezentacjach matematycznych i zagregowanych histogramach, co gwarantuje pełne bezpieczeństwo danych.

Detekcja Label Skew: Rozbieżność JS

Dlaczego rozbieżność Jensena–Shannona?

W przeciwieństwie do uproszczonych miar entropii, rozbieżność Jensena–Shannona (JSD) posiada pożądane cechy matematyczne:

- Jest symetryczna: $JS(P\|Q) = JS(Q\|P)$.
- Jest ściśle ograniczona w przedziale $[0, 1]$, co umożliwia łatwe zdefiniowanie stałego progu decyzyjnego.
- Idealnie wychwytuje różnice proporcji klas w zadaniach binarnych i wieloklasowych.

Zasada działania algorytmu

Krok 1: Każdy klient oblicza lokalny rozkład prawdopodobieństwa występowania etykiet klas i wysyła histogram do serwera.

Krok 2: Serwer wyznacza globalny rozkład uśredniony.

Krok 3: Obliczana jest maksymalna wartość JSD pomiędzy klientami a średnią globalną. Jeśli przekracza próg $\tau = 0.1$, ogłaszany jest stan skośności danych.

Formuła matematyczna JSD

Równanie rozbieżności Jensena–Shannona

Dla rozkładu klienta P oraz globalnego rozkładu referencyjnego Q , JSD definiowane jest na bazie dywergencji Kullbacka–Leiblera (KL) w następujący sposób:

$$JS(P\|Q) = \frac{1}{2}KL(P\|M) + \frac{1}{2}KL(Q\|M)$$

Gdzie M stanowi rozkład mieszany określony formułą:

$$M = \frac{1}{2}(P + Q)$$

Dzięki takiemu sformułowaniu unikamy problemu dzielenia przez zero występującego w czystej dywergencji KL, gdy niektóre klasy nie występują lokalnie u danego klienta.

Detekcja anomalii (Outlier Detection)

Analiza wag w drugiej rundzie FL

Aby wykryć anomalnych lub złośliwych klientów, system zbiera lokalne wagi modeli tuż po zakończeniu **drugiej rundy** uczenia federacyjnego (wykorzystując wyjściowy algorytm FedAvg).

Serwer wyznacza macierz odległości euklidesowych pomiędzy wszystkimi parami wektorów wag klientów.

Dlaczego akurat druga runda?

W pierwszej rundzie wagi są zaszumione losową inicjalizacją. W kolejnych rundach proces uśredniania rozmywa różnice. Druga runda daje najczystszy sygnał lokalnych trendów optymalizacyjnych.

Zabezpieczenie przed fałszywym alarmem

Stochastyczny charakter uczenia może powodować chwilowe skoki rozbieżności u uczących klientów. Aby temu zapobiec, badanie jest powtarzane kilkakrotnie (z kilkoma epokami lokalnymi).

Węzeł zostaje ostatecznie oznaczony jako **outlier** tylko wtedy, gdy jego skumulowany wskaźnik rozbieżności mieści się w 90. percentylu w co najmniej 4 próbach testowych.


Detekcja Feature Skew: Federated PCA

Zwalczanie przekleństwa wymiarowości

Surowe dane wejściowe (np. obrazy o wysokiej rozdzielczości) zawierają tysiące cech o wysokim poziomie szumu informacyjnego.

Bezpośrednia analiza odległości w tak wysokiej wymiarowości jest numerycznie bezużyteczna (przekleństwo wymiarowości).

Rozwiązaniem jest **rozproszona analiza głównych składowych (Federated PCA)**, która rzutuje dane na bezpieczną dwuwymiarową przestrzeń cech.



Rzutowanie klientów na wspólną przestrzeń cech

Matematyka rozproszonego PCA

Etap 1: Lokalna kowariancja

Każdy klient lokalnie oblicza wektor sum cech, sumy kwadratów oraz iloczyny skrzyżowane cech, niezbędne do odtworzenia macierzy kowariancji:

$$\Sigma_i = X_i^T X_i$$

Przesyłana jest wyłącznie macierz Σ , co uniemożliwia odtworzenie próbek.

Etap 2: Globalna projekcja

Serwer sumuje macierze lokalne, odtwarza globalną macierz kowariancji, wyznacza dwa najważniejsze wektory własne i odsyła je do klientów.

Klienci rzutują swoje dane na te wektory i zwracają jedynie centroidy rzutów. Serwer bada ich separację euklidesową (próg $\tau = 1.0$).

Tryb Single-Trial: Prompt Engineering

Wnioskowanie z GPT-4.1

Po zakończeniu diagnostyki EDA, zebrane informacje (Label Skew, Feature Skew, Outlier Risk) są kodowane w ustrukturyzowany prompt wejściowy dla LLM.

Rola modelu językowego polega na przetłumaczeniu tych abstrakcyjnych deskryptorów statystycznych na precyzyjny słownik parametrów optymalizacyjnych Flower.

Kluczowe innowacje promptu

- **Wbudowana fl_schema:** Model otrzymuje dokładną listę dozwolonych strategii i przedziałów liczbowych parametrów, co zwiększyło poprawność wyjścia z 2 na 5 do 5 na 5 przypadków testowych.
- **Few-Shot Prompting:** Umieszczenie konkretnych przykładów poprawnego kodu JSON w instrukcji systemowej; bez niego błędy występowały w 2 z 5 przypadków testowych.

Analiza formatów promptów wejściowych

Format-A: Dane surowe

Dostarcza modelowi surowe liczbowe statystyki rozkładów i odległości.

× **Słaba wydajność**

LLM słabo interpretują skomplikowane korelacje liczbowe bez wcześniejszego przetworzenia semantycznego.

Format-B: Flagi binarne

Dostarcza uproszczone flagi (TAK/NIE) określające obecność ryzyka skośności lub anomalii.

✓ **Najlepsza wydajność**

Jasny podział logiczny pozwala LLM na szybkie dopasowanie właściwej klasy algorytmów.

Format-C: Poziomy ryzyka

Wprowadza trzystopniową skalę ryzyka (Wysokie/Niskie/Brak).

● **Średnia wydajność**

Model wykazuje nieoczekiwaną niewrażliwość na gradację ryzyka, dając niespójne wartości parametrów.

Mechanizm walidacji i powtórzeń

Zabezpieczenie przed halucynacjami

Modele LLM, mimo zaawansowania, wykazują tendencję do generowania niepoprawnego kodu lub halucynowania nazw parametrów.

W środowisku produkcyjnym uruchomienie błędnej konfiguracji skutkuje awarią całego klastra Flower i stratą zasobów.

Wprowadzono autonomiczny **parser składniowy** sprawdzający zgodność wyjścia z dozwolonym schematem.

Pętla korekcyjna (do 3 prób)

Krok 1: Odczyt odpowiedzi i weryfikacja typów danych (np. czy `proximal_mu` jest float).

Krok 2: W przypadku błędu, system wysyła prompt zwrotny z precyzyjnym wskazaniem linii błędu kompilatora.

Krok 3: Przy braku poprawy po 3 próbach, system zgłasza błąd informacyjny (nie uruchamia automatycznie żadnej domyślnej strategii).

Wybór Format-B jako standardu

Przewaga prostoty nad nadmiarem danych

Badania nad promptami dowiodły, że **Format-B** (flagi tak/nie) pozwala modelowi językowemu na dokonanie najczystszej kategoryzacji semantycznej.

Wprowadzenie gradacji (Format-C) powodowało paradoksalne błędy: dla mniejszej skośności model potrafił przypisać wyższą karę regularizacyjną μ , co tłumiliło proces uczenia.

Główne uzasadnienie

Ograniczenie wyboru do binarnej oceny ryzyka stabilizuje proces wnioskowania LLM i eliminuje fluktuacje generowanych parametrów liczbowych. Pozwala to na przewidywalne i bezpieczne wdrażanie strategii w systemach krytycznych.

Tryb Multi-Trial: Bariery HPO

Koszt optymalizacji hiperparametrów

W scenariuszach, gdzie dopuszczalne jest wykonanie kilku prób treningowych, tradycyjne podejścia AutoML (np. Optuna z algorytmem TPE) napotykają barierę kosztów.

Optymalizacja Bayesowska wymaga zazwyczaj **50–100 pełnych procesów FL** do odnalezienia optimum.

W warunkach rozproszonych oznacza to ogromny narzut energetyczny i przeciążenie pasma komunikacyjnego klientów IoT.

Krytyczne ograniczenie brzegowe

Dla wielu urządzeń brzegowych zasilanych bateryjnie, wykonanie kilkudziesięciu pełnych treningów sieci neuronowej jest równoznaczne z rozładowaniem urządzenia i przerwaniem jego pracy operacyjnej.

Dlaczego Algorytmy Genetyczne?

Zalety wyszukiwania euklidesowego

Algorytmy genetyczne (GA) doskonale balansują eksplorację przestrzeni z eksploatacją najlepszych dotychczasowych osobników.

W warunkach skrajnie małego budżetu prób (sztywny limit do **8 prób**), GA potrafi wykryć obiecujące minima parametrów znacznie szybciej niż metody statystyczne.

Optymalizacja przebiega dwuetapowo: najpierw następuje selekcja obiecującej klasy strategii, a następnie lokalne dostrojenie jej parametrów.

Szybka konwergencja

Dzięki rygorystycznemu zachowywaniu najlepszych osobników (elitaryzm) i ukierunkowanym mutacjom lokalnym, algorytm genetyczny osiąga wyniki porównywalne z 50-próbowym przeszukiwaniem Optuna w zaledwie 8 podejściach.

Struktura wyszukiwania genetycznego

Generacja 1: Eksploracja

Rozmiar populacji: 4 unikalne osobniki.

Konfiguracje są losowane równomiernie z całej przestrzeni dopuszczalnych strategii (np. Krum, FedProx, FedMedian) i ich hiperparametrów.

Wszystkie próby są uruchamiane i oceniane pod kątem dokładności ważonej modelu.

Generacja 2: Eksploatacja

Wybór rodziców: Top-2 z globalnego archiwum.

Nowe 4 osobniki powstają poprzez mutacje rodziców. Typ strategii agregacji zostaje zamrożony, a modyfikacji ulegają wyłącznie jej parametry numeryczne w małym zakresie lokalnym.

Zapewnia to precyzyjne dostrojenie wartości wokół wykrytego optimum.

Ewolucja: Selekcja i Mutacja

Zasady mutacji numerycznych

Aby mutacje były matematycznie spójne, zastosowano odrębne reguły dla różnych typów zmiennych hiperparametrycznych:

Dla parametrów całkowitoliczbowych (np. liczba tolerowanych złośliwych klientów f w Krum):

$$x' = \text{clip}(x + \text{Unif}\{-1, 0, 1\})$$

Parametry rzeczywiste

Dla zmiennych ciągłych (np. μ w FedProx) mutacja polega na dodaniu małego szumu losowego:

$$x' = \text{clip}(x + \varepsilon, [a, b])$$

Gdzie $\varepsilon \sim \text{Unif}[-0.1, 0.1]$, a zakres zostaje przycięty do dopuszczalnych granic dziedziny $[a, b]$.

Zróźnicowanie domen badawczych

Aby dowieść uniwersalności zaproponowanego frameworku, autorzy przeprowadzili szeroko zakrojone testy na zbiorach danych o skrajnie odmiennych charakterystykach:

- **NASA Bearing Dataset:** Dane tabularyczne z czujników wibracyjnych. Wykorzystany do precyzyjnych symulacji kontrolowanej heterogeniczności.
- **CIFAR-10:** Referencyjny zbiór obrazów naturalnych. Podzielony metodą partycjonowania Dirichleta w celu indukcji silnego label skew.

Symulacje zaburzeń danych

Na bazie zbioru NASA Bearing stworzono sześć unikalnych scenariuszy badawczych:

1. Standardowy rozkład IID (baza porównawcza).
2. Label Skew (klienci posiadają inne proporcje klas).
3. Feature Skew (przesunięcie rozkładu cech przez szum Gaussa).
4. Noisy Labels (część etykiet losowo zaburzona).
5. Label Poisoning (pełne odwrócenie klas u jednego klienta).
6. Corrupted Client (połączenie szumu cech i zatrucia etykiet).

Dodatkowe domeny walidacyjne

Wine Quality

Tabularyczny (wieloklasowy).

Ocena jakości wina (skala 1–10) na podstawie cech fizykochemicznych. Rozszerza ewaluację danych tabularycznych o zadanie wieloklasowe.

Retina Dataset

Wizyjny (Medyczny).

Rzeczywista (niesymulowana) heterogeniczność wynikająca z różnic sprzętowych i demograficznych w szpitalach klinicznych podczas diagnostyki jaskry.

Sentiment140

Tekstowy (NLP).

Analiza sentymentu wpisów na portalu Twitter. Testuje odporność systemu na wysoką wymiarowość osadzeń językowych (embeddings).

CartPole (OpenGym)

Uczenie przez wzmacnianie.

Federated Reinforcement Learning (FRL). Zadanie kontroli fizycznej pod wpływem drastycznie różnych parametrów grawitacji u klientów.

Wyniki: Skuteczność detekcji

Precyzja diagnostyki statycznej

Wszystkie zaprojektowane moduły diagnostyczne wykazały się 100% zbieżnością z rzeczywistym, kontrolowanym stanem heterogeniczności danych:

- **Moduł Label Skew:** Zwracał niemal zerowe wartości JSD (< 0.0002) dla rozkładów IID i wysokie wartości (0.189 do 0.434) dla danych silnie zaburzonych.
- **Moduł Outlier:** Bezbłędnie flagował klientów z zatrutymi etykietami (label poisoning) we wszystkich powtórzeniach.

Stabilność numeryczna PCA

Wykrywanie Feature Skew za pomocą rozproszonego PCA dało wyraźny rozdział odległości centroidów:

- Rozkład IID: Odległość centroidów = 0.577
- Zaburzenie średnie: Odległość centroidów = 7.435
- Silne przesunięcie: Odległość centroidów = 15.060

Wyniki dokładności: NASA Bearing

Scenariusz	Empirical Best	GA (proponowane)	Single-Shot LLM	FedAvg	Empirical Worst
Label Skew	0.6729 ± 0.0149	0.6679 ± 0.0128	0.6360 ± 0.0058	0.6186 ± 0.0168	0.6236 ± 0.0205
Label Poisoning	0.6060 ± 0.0168	0.6223 ± 0.0195	0.6087 ± 0.0180	0.5543 ± 0.0258	0.5543 ± 0.0258
Noisy Label	0.6948 ± 0.0187	0.6882 ± 0.0233	0.6548 ± 0.0410	0.6393 ± 0.0500	0.6434 ± 0.0471
Feature Skew	0.7250 ± 0.0139	0.7112 ± 0.0449	0.7022 ± 0.0241	0.6806 ± 0.0347	0.6681 ± 0.0429
Corrupted Client	0.6058 ± 0.0258	0.6120 ± 0.0198	0.6265 ± 0.0219	0.5948 ± 0.0197	0.5838 ± 0.0230

Analiza: Single-Shot LLM vs FedAvg

Bezpieczny wzrost bez dodatkowych kosztów

Nawet w skrajnie ograniczonym budżecie **Single-Trial** (gdzie dozwolona jest tylko jedna próba uruchomienia FL), system z rekomendacją LLM wykazuje stałą przewagę nad ślepym algorytmem FedAvg.

Największa przewaga widoczna jest w środowisku wrogim (Label Poisoning), gdzie FedAvg załamuje się do dokładności 55.43%, podczas gdy LLM natychmiast sugeruje algorytm Krum, podbijając dokładność do 60.87%.

Marginalny koszt narzutu

Wybór dokonany przez model GPT-4.1 nie generuje dodatkowego narzutu podczas właściwego treningu klientów. Cały potok jednorazowej automatyzacji LLM (detekcja + wnioskowanie) kosztuje ok. 109s wobec 69s dla samego naiwnego treningu FL – to wciąż znacznie mniej niż 50-próbowe HPO w Optunie (1106s).

Wydajność wyszukiwania genetycznego

Redukcja zasobów o 84%

Aby uświadomić sobie wagę innowacji algorytmu genetycznego w trybie Multi-Trial, należy zestawić ze sobą liczby wymaganych prób optymalizacyjnych:

- Tradycyjna Optuna (Bayes): **50 pełnych treningów FL.**
- Zaproponowany Algorytm Genetyczny: **8 pełnych treningów FL.**

Stanowi to drastyczny krok naprzód w kierunku ekologicznego i zielonego uczenia maszynowego (Green AI).

Efekt ekologiczny i kosztowy

Drastyczne obcięcie liczby prób optymalizacyjnych z 50 do 8 bezpośrednio przekłada się na obniżenie rachunków za transfer danych komórkowych oraz mniejsze zużycie baterii na urządzeniach IoT o ponad 80% przy zachowaniu niemal identycznej precyzji modeli globalnych.

Analiza czasu wykonania i EDA

Koszt diagnostyki wstępnej

Pojawia się zasadnicze pytanie: czy faza detekcji heterogeniczności (EDA) nie trwa zbyt długo, niwelując zyski z szybkiego uczenia?

Cały proces diagnostyki EDA na zbiorze NASA Bearing trwa **73.96 sekund**, co odpowiada kosztowi zaledwie 63 rund zwykłego uczenia FedAvg.

Dla modeli, które trenują się przez setki rund, ten narzut początkowy jest całkowicie marginalny.

Rozbicie czasowe komponentów

Jedna runda FL (Baza)	1.16 s
Detekcja Label Skew	8.31 s
Detekcja Feature Skew	11.19 s
Detekcja Outliers	54.45 s

Złożoność obliczeniowa PCA

Skalowanie względem cech i próbek

Złożoność obliczeniowa po stronie klienta wynosi $O(Nd^2)$, gdzie N to liczba lokalnych próbek, a d to liczba cech wejściowych.

Po stronie serwera złożoność wynosi $O(Kd^2 + d^3)$, gdzie K to liczba klientów, a człon d^3 reprezentuje koszt dekompozycji spektralnej kowariancji.

Wniosek inżynierski

Ponieważ koszt rośnie kwadratowo wraz z wymiarem cech d , bezpośrednie stosowanie Federated PCA na surowych pikselach obrazów (gdzie d wynosi dziesiątki tysięcy) jest nieefektywne.

W takich przypadkach autorzy zalecają stosowanie **ekstrakcji cech** (np. za pomocą lekkich sieci ResNet-18) przed uruchomieniem PCA, co redukuje wymiar wejściowy do małego wektora osadzeń.

Skalowanie do dużej liczby węzłów

Zachowanie przy 10, 50 i 100 klientach

Aby sprawdzić, czy system nie załamuje się w miarę wzrostu rozproszenia sieci, przetestowano skalowalność potoku decyzyjnego dla zbioru CIFAR-10 na konfiguracjach liczących 4, 10, 50 oraz 100 węzłów.

W miarę wzrostu liczby węzłów, lokalne zbiory danych stają się coraz mniejsze i bardziej skrajnie zaburzone.

Stabilność przewagi


Eksperymenty dowiodły, że przewaga algorytmu genetycznego (GA) nad domyślnym FedAvg **rośnie wraz z liczbą węzłów**. Przy 100 węzłach i silnej skośności ($\alpha = 0.1$), FedAvg całkowicie stagnuje, podczas gdy GA pomyślnie wyprowadza model z kryzysu zbieżności.

Trendy zbieżności uczenia

Stabilizacja procesu uczenia

Poniższy wykres poglądowy ilustruje trajektorie zbieżności dokładności modeli w czasie rund treningowych pod wpływem różnych strategii agregacji przy silnej skośności danych.

Widoczna jest natychmiastowa stabilizacja i brak oscylacji w przypadku dynamicznie dobranych strategii genetycznych.



Generalizacja: Inne modalności

Od tekstu po Reinforcement Learning

Znakomita większość prac z zakresu automatyzacji FL ogranicza się wyłącznie do prostych klasyfikacji obrazów. Prezentowany framework łamie ten schemat:

- **Sentiment140 (NLP):** Z powodzeniem dobrano optymalne wagi agregacji dla klasyfikacji tekstu przy użyciu sieci TextCNN.
- **CartPole (Uczenie przez wzmacnianie):** Algorytm genetyczny pomyślnie zoptymalizował model DQN w warunkach skrajnych różnic fizycznych między klientami.

Dostosowanie metryk dla FRL

W uczeniu przez wzmacnianie standardowa dokładność ważona nie istnieje. Autorzy zastąpili ją **medianą średniej nagrody (reward)** z ostatnich rund treningowych, co pozwoliło na stabilną optymalizację agentów DQN.

Ważny limit: TinyBERT

Przy embeddingach TinyBERT (Sentiment140) wszystkie triale Optuna dały identyczne krzywe uczenia – silne pretrenowane reprezentacje zniwelowały różnice między klientami, czyniąc wybór strategii agregacji bez znaczenia.

Podsumowanie wdrożenia i korzyści

01

Bezpieczeństwo i stabilność

Bezbłędne odpieranie ataków typu label poisoning i tłumienie złośliwych aktualizacji bez potrzeby ciągłego nadzoru administratora bezpieczeństwa.

02

Demokratyzacja FL

Otwarcie drzwi do wdrożeń uczenia federacyjnego dla firm i instytucji nieposiadających dedykowanych zespołów R&D z zakresu matematyki optymalizacyjnej.

03

Oszczędność czasu

Skrócenie czasu potrzebnego na uruchomienie i optymalizację środowiska FL z kilku tygodni testów manualnych do zaledwie kilkudziesięciu minut zautomatyzowanego potoku.

Krytyka: Zależność od architektury

Wpływ lokalnego modelu na wyniki

Proces automatycznego wyboru strategii agregacji w zaproponowanym frameworku zakłada, że architektura lokalnego modelu ML (np. sieć CNN) jest stała i optymalna dla danego zadania.

W rzeczywistości, suboptymalna konstrukcja modelu lokalnego (np. zbyt mała liczba warstw lub złe współczynniki uczenia) całkowicie niweluje zyski płynące z optymalnej agregacji.

Poważna luka systemowa

Optymalizator agregacji próbuje „leczyć objawy” heterogeniczności na serwerze, podczas gdy „źródło choroby” leży bezpośrednio w złej konfiguracji hiperparametrów lokalnych u klientów, na co system nie ma żadnego wpływu.

Krytyka: Koszt obliczeniowy PCA

Problem z wysoką wymiarowością cech

Rozproszona metoda PCA, choć elegancka matematycznie, wymaga od klientów przesyłania macierzy iloczynów skrzyżowanych o wymiarze $d \times d$.

Dla nowoczesnych zadań uczenia maszynowego (np. analizy sekwencji genomicznych lub obrazów 3D wysokiej rozdzielczości), wymiarowość d sięga milionów.

Przesyłanie i dekompozycja macierzy o takim rozmiarze paraliżuje sieć i serwer agregujący.

Ograniczenie skalowalności

Autorzy sprytnie ominęli ten problem w CIFAR-10, stosując zamrożone embeddingi z ResNet-18.

Jednak w scenariuszach, gdzie nie dysponujemy pre-trenowanymi modelami i musimy uczyć reprezentacje cech od zera, faza diagnostyczna PCA staje się wąskim gardłem obliczeniowym, uniemożliwiając wdrożenie na urządzeniach brzegowych.

Krytyka: Wrażliwość na progi τ

Arbitralny wybór parametrów EDA

Wykrywanie skośności danych i anomalii opiera się na sztywnych progach decyzyjnych:

- Próg JSD dla Label Skew: $\tau = 0.1$
- Próg dystansu centroidów PCA: $\tau = 1.0$

Wartości te zostały dobrane przez autorów w sposób całkowicie empiryczny, ad-hoc, pod kątem użytych zbiorów danych.

Brak zdolności adaptacyjnych

Dla nowych, nieznanych wcześniej zbiorów danych, te arbitralne progi decyzyjne mogą okazać się zbyt czułe lub zbyt tolerancyjne, prowadząc do błędnych diagnoz heterogeniczności i w konsekwencji – do wyboru skrajnie suboptymalnych strategii agregacji.

Krytyka: Ryzyko halucynacji LLM

Niestabilność modeli generatywnych

Użycie modelu LLM (nawet tak zaawansowanego jak GPT-4.1) w pętli produkcyjnej systemów rozproszonych zawsze wiąże się z ryzykiem niedeterminizmu.

Mimo zastosowania walidatora i pętli powtórzeń, istnieje niezerowe prawdopodobieństwo, że LLM wygeneruje poprawną składniowo, ale matematycznie absurdalną wartość parametru.

Przykładowy scenariusz krytyczny

Dla średniego poziomu zaburzeń model językowy może zhalucynować i przypisać wartość $\mu = 100.0$ w FedProx. Taki parametr przejdzie pomyślnie testy walidacji składniowej, ale w praktyce całkowicie zablokuje uczenie modeli klienckich, marnując cenne zasoby obliczeniowe.

Krytyka: Ryzyko wycieku prywatności

Bezpieczeństwo macierzy kowariancji

Autorzy twierdzą, że przesyłanie lokalnych macierzy kowariancji $X^T X$ gwarantuje pełną ochronę prywatności, ponieważ nie ujawnia surowych próbek.

W świetle nowoczesnych badań z zakresu cyberbezpieczeństwa (np. rekonstrukcji danych na bazie kowariancji), twierdzenie to jest nadmiernym uproszczeniem.

Ataki rekonstrukcyjne (Inference Attacks)

Złośliwy serwer agregujący, posiadający dostęp do pełnej struktury kowariancji cech klienta, może za pomocą metod optymalizacyjnych zrekonstruować statystyczny profil danych wejściowych.

Jest to szczególnie niebezpieczne w medycynie, gdzie profil kowariancji może ujawnić obecność unikalnych markerów genetycznych pacjenta, naruszając rygorystyczne przepisy prawne.

Krytyka: Pomijanie asynchroniczności

Problem urządzeń powolnych (Stragglers)

W rzeczywistych sieciach brzegowych urządzenia klienckie mają skrajnie różne moce obliczeniowe i warunki sieciowe.

Niektóre urządzenia (tzw. **stragglers**) mogą potrzebować znacznie więcej czasu na wykonanie lokalnych epok lub przesłanie danych diagnostycznych EDA.

Zaproponowany system działa w trybie **ściśle synchronicznym**.

Blokowanie klastra

W przypadku awarii lub drastycznego opóźnienia sieci u jednego z 100 klientów, cały potok diagnostyczny serwera zostaje zablokowany, czekając na spóźnione statystyki PCA. Paraliżuje to działanie systemu i uniemożliwia jego stosowanie w sieciach mobilnych o zmiennej jakości sygnału.

Krytyka: Statyczny charakter wyboru

Założenie o niezmienności skośności

Framework dokonuje diagnozy heterogeniczności **jednorazowo, przed rozpoczęciem właściwego uczenia** (lub w trybie Multi-Trial ulega ewolucji na stałej konfiguracji).

W rzeczywistości, rozkłady danych u klientów brzegowych stale ewoluują w czasie (konceptyjne przesunięcie czasowe).

Brak dynamicznej rekonfiguracji

Jeśli po 50 rundach uczenia rozkład danych na telefonach użytkowników drastycznie się zmieni (np. z powodu zmiany pory roku lub trendów społecznych), raz dobrana przez LLM statyczna strategia agregacji staje się nieefektywna, a system nie posiada mechanizmu ciągłego monitorowania zmian.

Krytyka: Złożoność inżynieryjna

Problem z utrzymaniem kodu

Połączenie w jednym potoku bibliotek PyTorch, platformy Flower, parserów JSON, modeli językowych OpenAI API oraz algorytmów genetycznych tworzy potężny, skomplikowany technologicznie ekosystem.

Utrzymanie stabilności takiego systemu w warunkach produkcyjnych rodzi ogromne wyzwania DevOps.

Punkt zapalny awarii

Wystarczy jakakolwiek zmiana w strukturze odpowiedzi API OpenAI lub drobna modyfikacja formatu danych we Flower, by cały zautomatyzowany potok przestał działać, wymagając natychmiastowej i kosztownej interwencji programistów.

Krytyka: Ograniczona rola strategii przy silnych reprezentacjach

Wynik testu z TinyBERT jako sygnał ostrzegawczy

Autorzy sami przetestowali architekturę typu Transformer (TinyBERT na Sentiment140) i wykazali, że przy silnych, pretrenowanych reprezentacjach wybór strategii agregacji przestaje mieć znaczenie – wszystkie triale dały identyczne krzywe uczenia.

Oznacza to, że korzyści z frameworku są **odwrotnie proporcjonalne** do jakości reprezentacji cech lokalnego modelu.

Realna implikacja

Dla najbardziej praktycznie istotnych, dużych modeli (LLM, duże Transformery z bogatymi embeddingami), potencjalna wartość dodana automatycznego doboru strategii może okazać się marginalna – co ogranicza praktyczne zastosowanie frameworku właśnie w tych scenariuszach, gdzie FL jest dziś najbardziej pożądanym.

Krytyka: Brak analizy sieciowej

Ignorowanie kosztów transferu

Artykuł szczegółowo opisuje oszczędności czasu i procesora po stronie serwera oraz sprytne skrócenie prób HPO do 8.

Całkowicie pominięto natomiast rygorystyczny pomiar **narzutu komunikacyjnego (network overhead)** wygenerowanego przez przesyłanie statystyk diagnostycznych.

Kluczowa luka telekomunikacyjna

W uczeniu federacyjnym to transfer sieciowy (uplink) jest zazwyczaj głównym ograniczeniem systemowym, a nie moc obliczeniowa procesora. Brak dokładnego bilansu przesyłanych megabajtów podczas PCA i JSD uniemożliwia rzetelną ocenę efektywności ekonomicznej wdrożenia w sieciach IoT z limitowanym transferem danych.

Droga rozwoju: Integracja z NAS

Wspólne projektowanie sieci i agregacji

Aby rozwiązać problem zależności od architektury, proponujemy połączenie wyboru strategii agregacji z **automatycznym wyszukiwaniem architektury sieci (Neural Architecture Search – FedNAS)**.

System powinien jednocześnie ewoluować architekturę lokalnego modelu u klientów oraz dobierać dla niej strategię agregacji na serwerze.

Synergia optymalizacyjna

Dzięki takiemu podejściu, system automatycznie zmniejsza pojemność modelu u klientów o silnej skośności danych (zapobiegając przeuczeniu lokalnemu) i jednocześnie zwiększa parametry regularyzacji FedProx, osiągając pełną synergię sprzętowo-algorytmiczną.

Droga rozwoju: Prywatność różnicowa

Bezpieczna diagnostyka z DP

Aby całkowicie wyeliminować ryzyko ataków rekonstrukcyjnych na bazie macierzy kowariancji, proponujemy wdrożenie **adaptacyjnej prywatności różnicowej (Differential Privacy – DP)** podczas fazy EDA.

Do przesyłanych statystyk kowariancji dodawany jest kontrolowany szum matematyczny (np. szum Gaussa) skalowany za pomocą parametru budżetu prywatności ϵ .

Gwarancje matematyczne

Wprowadzenie DP zapewnia formalne, matematyczne gwarancje bezpieczeństwa (szum uniemożliwia rekonstrukcję surowych pikseli), a model LLM zostaje poinstruowany w prompcie o obecności szumu, dzięki czemu uwzględnia go podczas wnioskowania parametrycznego.

Dynamiczne przełączanie strategii

Monitorowanie dryfu w czasie rzeczywistym

Zamiast statycznego wyboru, proponujemy wprowadzenie mechanizmu **ciągłej weryfikacji dryfu (Online Drift Monitoring)**.

W regularnych odstępach czasu (np. co 10 rund), system przeprowadza szybkie, jednorundowe testy JSD na aktualizacjach wag.

Aktywna adaptacja

Jeśli system wykryje nagły wzrost skośności rozkładów u klientów, automatycznie wywoła lekki prompt LLM, który „w locie” przełącza strategię agregacji z FedAvg na FedProx, dbając o nieprzerwaną i optymalną zbieżność uczenia w zmieniających się warunkach.

Metoda Zero-Shot Transfer

Przenoszenie wiedzy między domenami

Wykorzystanie zaawansowanych modeli LLM otwiera drzwi do transferu wiedzy optymalizacyjnej pomiędzy skrajnie różnymi wdrożeniami.

Proponujemy budowę **globalnej bazy wiedzy o konfiguracjach**, gdzie LLM uczy się na bazie historycznych wdrożeń z innych dziedzin (np. medycyny, telekomunikacji).

Inteligentny start bez EDA

Dzięki technice transferu Zero-Shot, dla nowo uruchamianego klastra IoT o znanej specyfikacji geograficznej, model językowy potrafi natychmiast przepisać optymalną konfigurację bez potrzeby uruchamiania kosztownych czasowo i sieciowo faz diagnostycznych PCA, oszczędzając zasoby od pierwszej sekundy wdrożenia.

Samonadzorowane dopasowanie cech

Zwalczanie Feature Skew u źródła

Ostatnim, najbardziej zaawansowanym pomysłem jest wdrożenie metod **uczenia samonadzorowanego (Self-Supervised Learning – SSL)** w celu dopasowania reprezentacji przed agregacją.

Klienci, przed przystąpieniem do uczenia właściwego, wspólnie uczą lekki koder cech za pomocą kontrastowych metod reprezentacji (Contrastive Learning).

Całkowita eliminacja skośności

Contrastive Alignment wymusza na sieci reprezentowanie zbliżonych semantycznie obiektów w tym samym obszarze przestrzeni ukrytej, niezależnie od oświetlenia czy aparatu. Pozwala to na całkowitą eliminację zjawiska Feature Skew u źródła, czyniąc agregację odporną i stabilną.

Image Sources

- [https://media.geeksforgeeks.org/wp-content/uploads/20230717153929/Federated-Learning-\(1\).png](https://media.geeksforgeeks.org/wp-content/uploads/20230717153929/Federated-Learning-(1).png)
Source: www.geeksforgeeks.org
- https://www.mdpi.com/jsan/jsan-14-00037/article_deploy/html/images/jsan-14-00037-g004.png
Source: www.mdpi.com
- <https://www.frontiersin.org/files/Articles/1606499/xml-images/fimmu-16-1606499-g005.webp>
Source: www.frontiersin.org